刘祎铭

letusgo126@gmail.com · (+86) 130-0927-5407
github.com/LYMDLUT · lymdlut.github.io



教育背景

中山大学, 广州 2022 – 2025
硕士研究生 计算机视觉
人机物智能融合实验室 (HCP Lab)，导师为林倞教授 *(杰青，IEEE Fellow)*

大连理工大学, 大连 2018 – 2022
学士 电子信息工程　GPA : 4.59/5, 排名 4/206

工作与研究经历

大模型评测 (腾讯混元) 2025 年 7 月 – 至今

- **评测基准**：构建 **VisualNeedle**（信息密集场景下的主动视觉搜索，提出 crop-black 反事实设置，因果验证模型是否真正使用了工具返回的视觉证据）、**jy-crpg-bench**（开放世界 RPG 中的长程任务）、**EternalMath**（随人类新发现生长的数学基准）等评测基准
- **图文一致性评估**：构建 Agent 流水线，通过绘图指令拆解、构造问答对、LLM 综合打分评估图文一致程度，并自动归因到出错的类别/元素；在模型排序和未对齐元素判定上与人工高度一致，已优化时间与金钱成本并部署落地
- **视频打分模型训练**：将视频质量拆分为图文一致、视觉质量、动态质量三个维度，自建 1w 内部数据集，探索 SFT、RL、冻结打分在 VLM 上的应用，在自建和公开 bench 上均达到 SOTA，总结为技术报告 **Q-Save**

OpenRLHF 强化对齐算法与框架开发 2024 年 9 月 – 至今

- **框架**：主导 OpenRLHF 中 KL 损失算法，以及 DeepSpeed AutoTP、FSDP2+CP+TP 等训练后端开发
- **算法**：首次发现 GRPO 中 k3 loss 作为损失函数的有偏性，提出无偏的 k2 loss，博客被 Reinforce++ 引用，并总结为技术报告 **Rethinking KL Regularization in RLHF**

基于扩散模型的对抗净化防御算法 (中山大学 HCP Lab) 2023 年 3 月 – 2025 年 4 月

- **分析**：提出新的解释角度，认为 Diffusion 的对抗防御能力来源于随机性、且其 Loss landscape 局部并不平坦，而非既有研究中的“前向加噪减小自然图片与对抗图片的 KL 散度”或“高斯噪声的掩盖效应”，并首次将其与 Certified robustness 中的随机性区分开
- **方法**：提出扩散去噪对抗训练算法，通过平滑 Loss landscape 增强防御能力，在 DDPM、DDIM、VP-SDE、EDM 等扩散模型和多个数据集上一致提升

MMDetection 算法框架开发 (上海 AI Lab) 2022 年 7 月 – 2023 年 3 月

Detection Transformer 系列算法在 MMDetection 2.0 和 3.0 两个大版本深度重构与新增复现的核心成员

- 简化注册机制与继承关系，统一模块数据格式，大幅提升代码可读性、可维护性与运行效率，MMDetection 专门为本次工作新增 GitHub 分支 refactor-detr
- 复现重构 Conditional/DAB DETR、DINO 等复杂算法，统一混乱的模块命名与抽象逻辑，严格对齐性能指标并补充文档注释；受邀在 OpenMMLab 社区开放麦讲解本次工作

论文

- **ICLR 2025** *(第一作者)* Towards Understanding the Robustness of Diffusion-Based Purification: A Stochastic Perspective
- **EMNLP 2025 Demo** OpenRLHF: A Ray-based Easy-to-use, Scalable and High-performance RLHF Framework
- **投稿中** *(第二作者)* jy-crpg-bench: A Long-Horizon Benchmark for Frontier Models in an Open-World RPG
- **投稿中** *(共同一作)* VisualNeedle: Benchmarking Active Visual Search in Information-Dense Scenes
- **arXiv** Rethinking KL Regularization in RLHF: From Value Estimation to Gradient Optimization
- **arXiv** Q-Save: Towards Scoring and Attribution for Generated Video Evaluation
- **arXiv** EternalMath: A Living Benchmark of Frontier Mathematics that Evolves with Human Discovery
- **arXiv** DramaChain Bench: An End-to-End Benchmark for Short-Drama Generation

专业技能

- 关注方向：大模型评测（基准设计、自动打分与归因）、RLHF/RLVR、Agent RL
- 并行与训练：基于 DTensor 的 FSDP2 系列并行、DeepSpeed、Ray + vLLM 的 RLHF 训练链路